

Autoencoders

Representation learning y aplicaciones prácticas

David Charte Francisco Charte

22 jul 2019



UNIVERSIDAD
DE GRANADA



UJa Universidad
de Jaén

Introducción




Representación del conocimiento

Los modelos de representación del conocimiento (predictivos y descriptivos) operan sobre el **espacio de variables** de los patrones de datos facilitados

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.0	6	160	110	3.90	2.620	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6	160	110	3.90	2.875	17.02	0	1	4	4
Datsun 710	22.8	4	108	93	3.85	2.320	18.61	1	1	4	1
Hornet 4 Drive	21.4	6	258	110	3.08	3.215	19.44	1	0	3	1
Hornet Sportabout	18.7	8	360	175	3.15	3.440	17.02	0	0	3	2
Valiant	18.1	6	225	105	2.76	3.460	20.22	1	0	3	1


Problemas

Dispersión de los datos en altas dimensiones




Distancias

Conforme aumentan las dimensiones disminuye la **variación** entre las distancias



Ruido



de clase



en los datos



Anomalías




Soluciones

Selección de características

- Análisis de correlación
- Análisis de explicación de clases

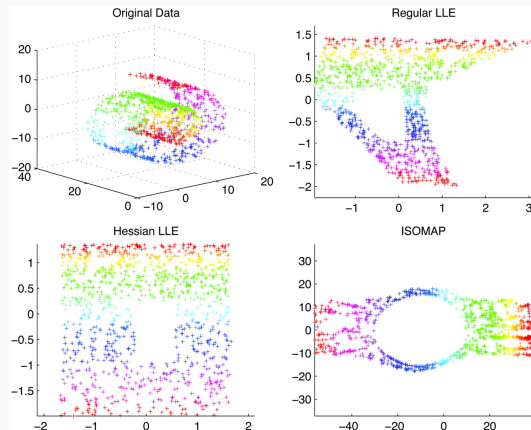
Reducción de características (estadística)

- Análisis de componentes principales (PCA)
- Análisis de componentes independientes (ICA)



Identificación de *manifolds* (topológica)

- Locally Linear Embedding
- Isomap
- Sammon mapping



Reducción de dimensionalidad (otras)

- Autoencoders
- t-SNE

Autoencoders

Introducción

Autoencoders:

- aprendizaje **de características** no supervisado
- con **redes neuronales**


Componentes:

- Codificador **f**
- Decodificador **g**

Objetivo: **$g(f(x)) \approx x$**



(opcionalmente, otras restricciones/propiedades)

Charte, D. et al.: A practical tutorial on autoencoders for nonlinear feature fusion: Taxonomy, models, software and guidelines. Information Fusion 44, 78–96 (2018).



Proyección en menos dimensiones


Undercomplete autoencoder: reducción de dimensionalidad




Reducción de ruido (en imágenes)

Denoising autoencoder: Entrena con **datos ruidosos**

⇒ Sus **reconstrucciones** eliminan ruido



Test → Ruido → Limpieza



Xie, J., Xu, L., Chen, E.: Image denoising and inpainting with deep neural networks. In: Advances in neural information processing systems. pp. 341–349 (2012)

Detección de anomalías

Entrenar con **datos normales**




Los datos anómalos provocarán alto **error de reconstrucción**


Por ejemplo: **detección de transacciones fraudulentas**

Sakurada, M., Yairi, T.: Anomaly detection using autoencoders with nonlinear dimensionality reduction. In: Proceedings of the MLSDA 2014 2nd Workshop on Machine Learning for Sensory Data Analysis. pp. 4–11. ACM (2014).

Error de reconstrucción en entrenamiento

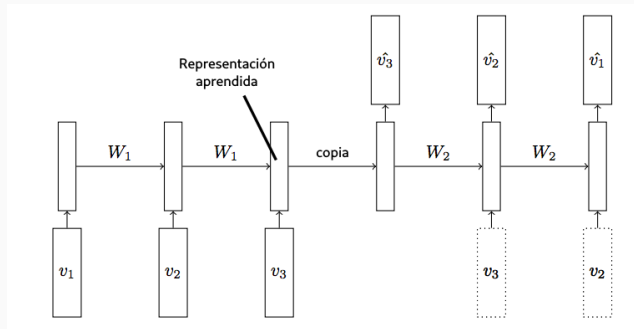


Error de reconstrucción en test (entre 80 y 90 s hay anomalías)



Predicción del mercado de valores

LSTM autoencoder: modelado de series temporales





Bao, W., Yue, J., & Rao, Y. (2017). A deep learning framework for financial time series using stacked autoencoders and long-short term memory. PloS one, 12(7), e0180944.

Otras

- Autoencoder binario: hashing semántico
- Autoencoder *sparse*, convolucional, LSTM: mejoras en rendimiento de clasificación
- *Denoising autoencoder*: mejora de calidad de voz
- *Variational autoencoder*: aprendizaje de *manifolds* y generación de datos
- *Correspondence autoencoder*: traducción (incluso con reordenaciones)

Trabajo en progreso: autoencoders para separabilidad de clases

Penalizar que las **codificaciones** tengan clases distintas poco separables



Conclusiones

Conclusiones

El aprendizaje de representaciones tiene **muchas aplicaciones**

Los autoencoders son **versátiles** y se pueden adaptar

Autoencoders

Representation learning y aplicaciones prácticas

David Charte Francisco Charte

22 jul 2019



UNIVERSIDAD
DE GRANADA



UJa Universidad
de Jaén